

1)  $a(x) = \text{sign}(f(x))$ ,  $f(x)$  - дискриминантная ф-ия,

например:  $a(x) = \text{sign}(\langle w, x \rangle + w_0)$

2) ответ:  $y: f(x_i)$ , частный случай:  $y_i (\langle w, x_i \rangle + w_0)$

$a(x) \neq y_i \Leftrightarrow \text{ответ} \leq 0$

3) достаточно просто добавить признак  $x_{n+1} = 1$

и поставить  $w_{n+1} = w_0$

4)  $Q(a, x^l) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] \Leftrightarrow \frac{1}{l} \sum_{i=1}^l [M_i \leq 0] \text{ (из 2)}$

5)  $w = 0$

6)  $Q(a, x^l) = \frac{1}{l} \sum_{i=1}^l L(M_i)$

7)  $L(a, x)$  показывает ошибку алгоритма на объекте  $x$ , причём  $L(a, x) \geq 0$ . Для лёгкости оптимизации стараются выбирать  $L$ -выпуклыми.

8) можно штрафовать только за оптимизационный ответ в задаче классификации

8) нешадная  $L = I(M \leq 0)$

немонотонная  $L = (1 - M)^2$

9) регуляризация - штраф за сложность модели  
в линейных моделях - это штраф за большие веса



$L_1$ -регуляризатор  $\sum_{i=1}^n |w_i|$

$L_2$ -регуляризатор  $\sum_{i=1}^n |w_i|^2$

сбалансированная  $\alpha \sum_{i=1}^n |w_i| + \beta \sum_{i=1}^n |w_i|^2$ ,  $\alpha + \beta = 1$

10) Обобщающая способность определяется ф-ой  $Q(\alpha(X^L), X^K)$  на train-выборке  $X^L$  и test-выборке  $X^K$   $X^L \cap X^K = \emptyset$ . При переобучении функция будет болеть, регуляризатор поможет это побороть.

11) Выход из минимума даёт сильное увеличение ф-ии.

12) Увеличивает функционал при выходе параметров алгоритма за допустимые границы.

13) Регуляризатор увеличивает значение ф-ии риска, потянув с ней.

15) реакция ответа

	1	0
1	TP	FP
0	FN	TN

$$\text{accuracy} = \frac{TP + TN}{P + N}$$

$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{recall} = \frac{TP}{P}$$

16)  $FPR = \frac{FP}{N}$

$$TPR = \frac{TP}{P}$$

ROC-кривая - график зависимости  $TPR(FPR)$  AUC - площадь под графиком



18) сортируем выборку  $X^L$  по значениям дискримин. функции, функции  $(FPR_0, TPR_0) = (0; 0)$ , а дальше пересчитываем FPR, TPR при добавлении нового объекта и ставим точку на графике.

~3.2.

Минимиз. логвкрдн. функцию потерь:

$$Q(x, w) = \sum_{i=1}^n L(y_i, \hat{y}_i) + F(w) = \frac{1}{n} \sum_{i=1}^n y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i) + F(w) = \frac{1}{n} \sum_{i=1}^n y_i \log (f(w, x_i)) + (1 - y_i) \log (1 - f(w, x_i)) + F(w) \rightarrow \min$$

Это аналогично максимизации функции правдоподобия

$$\frac{1}{n} \sum_{i=1}^n (\hat{y}_i)^{y_i} \cdot (1 - \hat{y}_i)^{1 - y_i} \cdot e^{-F(w)} = \frac{1}{n} \sum_{i=1}^n (f(w, x_i))^{y_i} \cdot (1 - f(w, x_i))^{1 - y_i} e^{-F(w)} = \frac{1}{n} \sum_{i=1}^n p(x_i, y_i | w) \cdot e^{-F(w)}$$

Рассмотрим вес.  $x, y$ -во с расф.  $p(x, y | w)$

$p(w) = p(w, \lambda) = e^{-F(w)}$  - нормальная вес.  $\lambda$  - гиперпараметры

$$\Rightarrow \frac{1}{n} \sum_{i=1}^n p(x_i, y_i | w) e^{-F(w)} = \frac{1}{n} \sum_{i=1}^n p(x_i, y_i | w) p(w) = p(x, y)$$

$\Rightarrow$  регуляризатор играет роль априорного распределения весов.

$L_1$ -регуляризация

$w \in \mathbb{R}^n$  имеет  $n$ -мерное расф. Лапласа



$$p(\omega, c) = \frac{1}{(2c)^n} \exp\left(-\frac{\|\omega\|_1}{c}\right), \quad \|\omega\|_1 = \sum_{i=1}^n |\omega_i|$$

все веса независ., с нулевым мат. от. и един. дисперсией.  $c$  - гиперпараметр, тогда, логарифмируя:

$$-\ln p(\omega, c) = \frac{1}{c} \sum_{i=1}^n |\omega_i| + c(\omega) - \text{регуляризатор по } L_1 \text{ норме}$$

$L_2$ -регуляризация

$\omega \in \mathbb{R}^n$  имеет норм. распр.

$$p(\omega, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{\|\omega\|^2}{2\Sigma}\right)$$

после регуляризации:

$$-\ln p(\omega, \Sigma) = \frac{1}{2\Sigma} \|\omega\|^2 + c(\omega) - L_2 \text{ регуляризатор}$$

~3, 4.

Kernel Trick

$$x_1^2 + 2x_2^2 = 3$$

$$k(x, y) = \langle x, y \rangle^2 = (x_1 y_1 + x_2 y_2)^2 = x_1^2 y_1^2 + 2x_1 y_1 x_2 y_2 + x_2^2 y_2^2 = \langle (x_1^2, x_2^2, \sqrt{2} x_1 x_2), (y_1^2, y_2^2, \sqrt{2} y_1 y_2) \rangle$$

$$\text{отобж. } \psi(x_1, x_2) \rightarrow (x_1^2, x_2^2, \sqrt{2} x_1 x_2)$$

Линейная поверхность в  $K$ :

$$\langle (x_1^2, x_2^2, \sqrt{2} x_1 x_2), (w_1, w_2, w_3) \rangle + w_0 = w_1 x_1^2 + w_2 x_2^2 + w_3 \sqrt{2} x_1 x_2 + w_0 = 0 \quad \left| w = \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix} w_0 = -3 \right| = x_1^2 + 2x_2^2 - 3 = 0$$



# $l_1$ -регуляризация

ограничение  $l_1$ -нормы весов членом

добавление штрафа с его  $l_1$ -нормой

по Т. Куна - Фракера

Если  $\exists$  решение  $w = (\hat{w}_1, \dots, \hat{w}_n)$  для задачи с ограничением

$$\begin{cases} \| \langle \hat{w}_i, x \rangle - y \| ^2 \rightarrow \min \\ \sum_{i=1}^n |w_i| - w \leq 0 \end{cases}, \text{ то}$$

$\exists$  вектор  $\lambda = (\lambda_1, \dots, \lambda_n)$ , такой, что выполнены

условия:

$$1) \min (\| \langle \hat{w}_i, x \rangle - y \| ^2 + \lambda (\sum |w_i| - a) =$$

$$= \| \langle \hat{w}_i, x \rangle - y \| ^2 + \lambda (\sum |\hat{w}_i| - a)$$

$$2) \lambda (\sum |\hat{w}_i| - a) = a$$

$\Rightarrow$  2 задачи эквивалентны и приводят к одному решению.

## ~ 3.6.

$$\text{PRECISION} = \frac{\text{верно угаданные объекты 1-го класса}}{(\text{общее количество объектов, которых мы предсказали 1-ый класс})}$$

$$\text{RECALL} = \frac{\text{верно угаданные объекты 1-го класса}}{\text{количество объектов 1-го класса}}$$

$$\text{ACCURACY} = \frac{\text{количество верных предсказаний}}{\text{общее кол-во верных предсказ.}}$$



ROC и AUC уже расписаны в п. 3.1

анализируйте тоже :)